

2026 年中国国际大学生创新大赛（项目提交材料）

方向 1B | 科学实验任务规划与反馈迭代

赛道一：科学实验任务规划与反馈迭代 | 项目编号：XH-202619 | 项目名称：虚拟学生试验台

P1 | 作品信息与核心结果

团队信息/成员信息（见报名系统登记）

作品编码：610449

2026年度中国青年科技创新“揭榜挂帅”擂台赛
学生赛道
报名表

推报学校名称：北京师范大学

揭榜榜题名称：XH-202619 基于国产开源大模型的AI Scientist技术研发与示范应用
（以发榜单位对外发布的榜题名称为准，请勿改动）

榜题发榜单位：浙江阿里巴巴云计算有限公司

申报作品名称：教育智研:面向教育学研究的一体化AI Scientist

申报者姓名：杨洲 王跃然 陈晓冬 上官润智
（全部成员，按顺序填写，且不可更改）

申报者情况	姓名	杨洲	性别	男	出生年月	2007-08-28
	所在学校及院系	北京师范大学人工智能学院				
	在读学历	本科	专业	人工智能专业		
	年级	本科一年级	学制	4年	入学时间	2025
	作品全称	教育智研:面向教育学研究的一体化AI Scientist				
	毕业论文题目	无				
合作者情况	通讯地址	北京北京市海淀区北太平庄街道北京师范大学		邮政编码	100875	
				联系电话	15807303750	
	姓名	性别	出生年月	学号	在读学历	年级
	王跃然	男	2007-02	202511081024	本科一年级	北京师范大学人工智能学院
	陈晓冬	男	2005-10	202411031054	本科一年级	北京师范大学人工智能学院
	上官润智	男	2005-12	202511081057	本科一年级	人工智能学院
指导教师情况	姓名	性别	出生年月	职称	工作单位及职务	
	钟方威	男	1993-12	副教授	北京师范大学人工智能学院 北京师范大学人工智能学院人工智能教研室成员	
资格认定1	经审核，以上全部参赛学生作者为2026年6月1日以前正式注册的全日制非成人教育的各类高等院校在校专科生、本科生、硕士/博士研究生（不含在职研究生）。					
	学校学籍管理部门意见					
审核单位名称：（此处加盖审核单位公章）						
年 月 日						

第1页，共3页

第2页，共3页

作品基本信息

项目字段	实际内容
项目名称	虚拟学生试验台
提交方向	方向 1B：科学实验任务规划与反馈迭代
项目编号	XH-202619
核心场景	教育干预虚拟实验与研究计划迭代
模型与模式	Qwen 语言层；BKT+ACT-R/L-Model 数值层；离线可复现

本作品核心主张

- 教育研究者如何在不直接占用真人样本的情况下，先用多主体虚拟学生模型规划并执行教育干预实验，再依据仿真结果、稳健性分析和专家反馈修订下一轮方案？
- 将研究目标转成可执行实验配置：生成学生/教师/家长档案，设置对照与干预臂，运行 BKT+ACT-R 认知引擎和 L-Model 连续时间仿真，输出效应量、置信区间、子群差异、失败记录和研究计划。
- 结果 1：固定 seed 案例可复现 100 名学生、20 名教师、100 名家长、90 天、5 个干预臂的完整运行包。
- 结果 2：系统把效应量、稳健性、失真和人在回路反馈写回下一轮计划，形成可追溯的实验迭代链。
- 局限：当前结果来自合成画像和离线确定性回退，尚未完成真实学生实验、真实数据校准和 Qwen 实时调用证据；所有结论均为实验规划或方向性证据。

官网提交要求提示

- 本稿按 1B 模板控制在 20 页以内；演示可通过本地后端和前端入口复现，离线模式不依赖外部 API。
- 模型使用通义千问接口作为问题理解与叙事层；无 API 密钥时自动切换确定性离线回退，并在结果中标注模式。
- 重点展示实验规划、仿真执行、数据分析、异常/失败处理、专家反馈和第二轮方案变化；不把虚拟结果表述为真人因果结论。
- 演示视频为可选材料；本稿提供固定 seed 运行包和结构化输出作为离线复核依据。

P2 | 作品目标与实际完成内容

团队实际解决的问题

团队实际问题：传统教育干预往往先做真人试验，成本高且难以解释中介机制。本项目先在可控虚拟环境中检验干预方向、执行条件和风险边界，再决定是否进入真人试验。

本作品实际完成的工作

已实现：多主体档案生成、干预目录与参数校验、6 臂分配（5 个干预+对照）、90 天 L-Model 仿真、Hedges' g 与 95% CI、反事实、稳健性、子群/场景比较、失败降级、报告和专家反馈接口。

本作品形成的完整闭环

研究目标 → 实验任务规划 → 配置校验 → 虚拟实验执行 → 原始轨迹与指标 → 结果判断 → 反馈修订 → 第二轮计划。每一轮保存 seed、配置、版本、结果和变更原因。

- 主要产出：可执行实验配置、对照/干预分配、日粒度轨迹、效应量与 CI、异常记录、研究计划和下一轮变更清单。
- 已完成范围：固定 seed 代表性案例和软件链路验收；未完成范围：真人实验、真实数据接入、外部仪器闭环。
- 与一次性问答的区别：系统会实际运行多主体仿真，数值由认知和时间模型计算，结果会触发参数/方案反馈，而不是只生成文字建议。

P3 | 本作品采用的科学逻辑与实验判断

团队实际采用的判断原则

判断环节	实际采用的规则	输出
目标与约束	目标、对象、干预、对照、指标必须可执行	任务配置
计划转实验	样本、时间窗、seed、分组和停止条件完整	运行前校验
结果判断	效应量、CI、稳健性和异常共同判断	支持/削弱/未知
反馈迭代	记录变更字段和原因，不覆盖上一轮	新版本计划
升级边界	合成仿真不得直接升级为真人结论	人工复核

本作品的科学逻辑

判断原则：先检查目标是否可操作、变量和对照是否明确、观测指标是否可记录；再检查仿真结果是否支持、削弱或无法判断原计划。任何 CI 跨零、异常或数据缺失都保留为限制，不自动判为成功。

P4 | 本作品实际使用的数据、资料与实验条件

已实际使用的内容

数据/工具	实际使用	规划与判断作用	已知边界
合成画像	100 学生/20 教师/100 家长	生成可控实验对象	非真实个体
BKT+ACT-R	知识与遗忘状态	计算学习轨迹	需真实数据校准
L-Model	90 天多主体仿真	执行干预和事件	无真实仪器
文献基线/固定 seed	literature_reference.py + case-20260821-100	复现与版本比较	单一代表性案例

实际处理方法

- 当前运行数据为合成画像和结构化仿真日志；数据来源、seed、代码版本和运行模式写入 JSON 元数据。
- 学生/教师/家长使用统一 ID；时间统一为仿真日，干预起止日和指标窗口固定写入配置。
- 缺失、异常和冲突由输入校验、PrivacyGuard 和确定性回退处理；无法可靠判断的记录进入人工复核队列。
- 虚拟环境边界包括样本规模、90 天时间窗、5 个干预臂、合成画像和无真实仪器；这些边界在报告中显式标注。

P5 | 本作品采用的评价方法

实际评价方案

评价维度	方法	评价结果	对下一轮影响
可执行性	配置 schema/范围校验	缺项则停止运行	补齐必填字段
效果方向	增益与 Hedges' g	仅作方向性证据	降低措辞强度
不确定性	95% CI/稳健性	CI 跨零则不升级结论	增加验证要求
反馈闭环	HITL 版本记录	变更可追溯	生成第二轮计划

评价口径说明

- 重点评价：实验是否可执行、指标是否可观测、结果是否可复现、失败是否留档、第二轮是否有可解释变化。
- 程序负责配置校验、分组、仿真、统计和日志；模型负责问题理解与文字组织；团队成员负责研究边界、异常复核和是否进入真人试验的判断。
- 第一轮和第二轮保持同一评价口径（目标、指标、CI 和失败记录）；变化只来自反馈后的计划、参数或证据边界，并记录变更原因。
- 当结果异常、CI 跨零、关键数据缺失或专家提交反馈时暂停自动推进；由研究者决定继续生成、修改计划或停止。

P6 | 系统总体架构与技术闭环

本作品真实架构

真实架构：问题输入 → 任务规划器 → 配置/约束校验 → 学生/教师/家长生成 → BKT+ACT-R/L-Model 仿真 → 指标与失败分析 → 报告/计划 → HITL 反馈。Qwen 位于问题理解和叙事层，不裁定数值对错。

方向1B：科学实验任务规划与反馈迭代闭环



实验模块	输入	核心计算	输出	与下一轮关系
研究目标与约束	问题/对象/指标	schema 校验	任务卡	进入计划
实验任务规划	干预/对照/seed	分组与停止条件	运行配置	进入执行
实验执行	配置+画像	BKT/ACT-R/L-Model	轨迹/事件	进入分析
数据分析与判断	轨迹/分组	g/CI/稳健性	结果卡	触发反馈
反馈与下一轮	结果/人工意见	变更审计	版本计划	再次执行

技术闭环的关键设计

它不是一次性实验方案：执行结果会回到任务规划、指标选择、干预参数或措辞边界；相同输入和 seed 可复现轨迹，不同版本保留差异和原因。

P7 | Qwen 使用方式与上下文工程

Qwen 在本作品中的实际作用

模块	实际使用
Qwen 语言层	问题结构化、变量说明、结果叙事
输入约束	结构化 schema、字段范围、隐私过滤
运行模式	有密钥时实时调用；无密钥时确定性回退
数值裁定	不由 Qwen 决定；由认知/仿真/统计模块计算
人工协同	研究者审查边界、异常和升级条件

上下文组织

结构化上下文包含研究目标、目标人群、干预/对照、证据边界、参数约束、历史结果、异常、人工反馈和下一轮修改项。

- 措施：固定 schema、输入范围校验、来源与版本字段、PrivacyGuard 脱敏、失败降级和原始运行包留档。
- 实验前更新：目标、对照、干预剂量、样本规模、时间窗和停止条件均先写入配置并校验。
- 反馈改变的是计划参数、证据权重和边界说明，不直接改写已产生的数值轨迹；新一轮使用新版本号和变更原因。

Qwen 在本作品开发过程中的应用

本项目在开发过程中依靠干问系列模型进行工程构建和优化，以下给出部分阿里云百炼平台调用 api 记录：



P8 | 实验任务规划方法

本作品实际采用的规划过程

规划环节	实际内容	形成的中间产物	可执行约束
定义目标	家长自主支持与控制监督比较	目标/指标卡	动机/坚持度/成就
确定顺序	校验→分组→仿真→分析	流程版本	固定 seed/时间窗
选择数据	合成画像+运行日志	数据清单	来源单独标注
设置停止	CI 跨零/异常/缺失触发复核	停止条件	不自动判成功
反馈与停止	专家意见/异常	下一轮变更清单	需人工确认

实际计划输出

计划片段：固定 seed=20260821；100 名学生随机分到对照与 5 个干预臂；运行 90 天；每日记录成就、动机、疲劳和事件；比较最终增益并计算 Hedges' g 与 95% CI；CI 跨零或数据异常时进入人工复核。

P9 | 实验或仿真实际执行与数据获取

本作品实际完成的执行过程

执行环境	使用的模块/工具	主要输入	原始输出	如何进入反馈
离线仿真	Python 后端/L-Model	固定 seed 配置	日轨迹/事件	比较预期与实际
统计分析	NumPy/统计模块	分组增益	g/CI/稳健性	触发边界提示
报告生成	ReportWriter/M8	结果卡	研究计划	专家提交意见

执行说明

- 执行前检查：样本数、干预臂、seed、时间窗、ID 唯一性、指标字段、数据来源和隐私等级。
- 原始轨迹保留在运行包；报告只导出聚合指标、配置摘要和必要的失败记录。
- 合成数据用于离线复现，真实数据接口单独标注来源；两者不混合计算，避免把回退数据误写成真实校准。

P10 | 数据分析、质量控制与反馈形成

本作品实际采用的分析过程

分析环节	实际输入	系统输出	人工判断	下一轮动作	状态
执行前检查	配置/数据 schema	错误清单	是否修正	补齐配置	已实现
效果分析	基线/终点增益	g 与 95% CI	是否支持方向	调整措辞/样本	已实现
异常值与失败	运行日志	失败原因	是否重跑	保留失败记录	已实现
预期比较	计划指标/实际指标	偏差摘要	是否停止	修改下一轮	已实现

结果如何变成反馈

- 直接进入反馈的原始量：分组、基线/终点成就、日轨迹、干预暴露、异常和失败状态。
- 确定性计算：均值、增益、Hedges' g、95% CI、场景/子群差异和稳健性；模型只解释结果，不替代统计计算。
- 关键判断由规则与研究者共同完成：CI 跨零、失真、样本不足或停止条件触发时，不升级为科学结论。

人工反馈字段包括评论、目标对象、证据充分性、建议动作、提交人和时间戳；反馈写回下一轮

P11 | 本作品实际采用的反馈与计划调整方法

已实现或实际使用的反馈机制

实际反馈信号	系统识别	对当前判断	下一轮调整	责任主体
CI 跨零	统计摘要	候选而非结论	增加验证	研究者
数据缺失	schema/日志	结果不可判	补数据或停止	系统+研究者
效果偏离	预期比较	方向需复核	改参数/对照	研究者
专家意见	HITL 记录	边界更清楚	改计划措辞	专家/团队

一项真实调整示例

代表性分析：case-20260821-100 中，I3_feedback 点估计最高（ $g=0.551$ ），95% CI 为 $[-0.144,1.246]$ 并跨零，因此第一轮只保留为候选方向，不判定为已证实效果；下一轮需扩大样本或进入真人验证。

P12 | 完整运行流程与实际失败处理

一次完整运行

流程图对应：目标定义→计划生成→执行前校验→90 天仿真→指标计算→异常/失败分流→专家反馈→第二轮计划；反馈可回到目标、配置、指标或停止条件。

本作品实际出现或主动测试过的情况

实验条件	系统设置	可观察结果	停止/反馈
样本	100 学生/20 教师/100 家长	各组增益	样本不足则限制外推
时间	90 天，固定 seed	日轨迹	异常/缺失即复核
干预	5 个干预臂+对照	g/CI/场景差异	CI 跨零不升级

- 系统自动产生：格式/范围错误、运行失败、缺失字段、CI 和稳健性摘要、与预期不一致提示。
- 研究者判断：是否补充证据、是否修改干预、是否调整样本/时间窗、是否停止或进入真人实验。
- 保留的前后变化：反馈前后的配置版本、变更字段、变更原因、运行 ID 和结果差异；不删除失败轮次。

P13 | 代表性案例选择与实际设置

为什么选择这个案例

- 科学目标：检验家长自主支持相较控制监督是否改善学习动机、坚持度与成绩增益。
- 选择原因：该问题能同时展示家长—学生关系、教师中介、固定 seed 仿真、5 个干预臂、反事实和反馈修订。
- 可展示能力：实验配置、组间比较、Hedges' g /CI、日轨迹、异常处理、报告生成和 HITL 反馈。
- 不能代表：真实学生个体、所有学科、真人 RCT、真实数据校准或物理实验仪器结果。

案例的实际初始条件

case-20260821-100：seed=20260821，100 名学生、20 名教师、100 名家长，90 天仿真，5 个干预臂与 1 个对照组；数据为合成画像，运行模式为 offline deterministic fallback。

案例	实际内容
case-20260821-100	教育干预问题：家长自主支持相较控制监督是否改善学习动机、坚持度与成绩增益？
运行配置	seed 20260821；100 学生；20 教师；100 家长；90 天；5 干预臂
数据来源	synthetic personas；offline deterministic fallback；无真实数据文件
代表性	展示完整规划—执行—分析—反馈链，不代表真人效果
关键结果	I3 点估计 $g=0.551$ ；95% CI[-0.144,1.246]跨零

P14 | 第一轮实验任务计划

第一轮实际计划

轮次	实验任务	主要输入	前置条件	预期观察	来源/责任	停止条件
1	家长支持干预比较	目标/配置/seed	字段完整	动机/坚持/成就变化	系统执行+团队审查	CI 跨零/异常
2	反馈修订后重跑规划	上一轮结果/意见	变更有原因	边界和可执行性改善	团队复核	仍无法判断
3	真实验证准备	真实数据/伦理方案	外部条件满足	真人指标与仿真对照	研究者负责	伦理/数据未就绪
停止与归档	CI/异常/证据不足	暂停升级并保留日志	下一轮计划或项目终止	研究者复核后决定	工程审计记录	需人工确认

计划形成过程

- 第一轮使用目标问题、合成画像、固定 seed、90 天时间窗、5 个干预和对照组，并预先定义成就/动机/坚持度指标。
- Qwen/语言层负责问题结构化、变量说明和计划文字；BKT+ACT-R、L-Model 和统计模块负责可计算执行。
- 通过配置 schema、ID/范围校验、运行前检查和固定 seed 确认可执行；不满足条件的任务进入失败记录。
- 人工未修改第一轮数值；人工仅审查边界、CI 跨零和是否可把结果升级为下一轮实验计划。

P15 | 第一轮实验执行与结果

第一轮执行状态：代表性案例已完成虚拟执行并生成日轨迹、事件日志、5 臂效应量和 95% CI；本轮未接入真人样本或真实实验仪器。

第一轮实际执行

轮次	实际对象/指标	原始数据	分析输出	与预期的差异	时间/模式
1	100 学生；动机/坚持/成就	日轨迹/分组日志	5 臂 g/CI	I3 最高但 CI 跨零	90 天/离线
2	计划边界/失败字 段	版本差异/反馈	修订清单	真实验证仍缺	工程迭代
3	真人样本与真实 数据	未执行	无	待外部条件	未开始
真人验证准 备	真实样本与伦理 方案	尚未采集真人数 据	待伦理、授权与 样本条件	不纳入当前效果 结论	后续研究者负责

第一轮实际评价

实际反馈信号	评价口径	第一轮结果	是否达到预期	确定动作
I3 点估计最高	g+95% CI	g=0.551, CI 跨零	未达到科学结论标准	保留为候选
合成数据	来源审计	无真实文件	未达到真实校准	标注 synthetic
失败/异常	日志与 schema	可留档	达到工程可追溯要求	保留并人工复核

P16 | 第一轮问题分析与调整依据

团队实际发现的问题

第一轮决策	判断依据	未达到的标准	第二轮实际动作	责任人
不升级结论	CI 跨零/合成数据	真实验证	降低措辞强度	团队
保留方向	点估计与机制合理	外部证据	列入候选计划	研究者
增加审计	失败与边界	无	补齐字段/复核节点	系统+团队

调整逻辑

- 实际反馈：CI 跨零且当前为合成数据，因此降低结论强度，增加真实数据/真人验证要求，并把样本、证据和停止条件列为下一轮必填项。
- 第二轮增加：证据来源字段、失败/异常留档、稳健性检查和人工复核节点；不删除对照组，也不修改已完成轮次。
- 保持不变：固定 seed 可复现机制、同一主要指标和 CI 口径；原因是需要比较版本变化而不混淆评价标准。
- 预期改善：减少把合成方向性证据误写成真实效果的风险，提高计划可执行性和复核效率。

P17 | 第二轮实验计划、执行与结果

第一轮与第二轮的实际变化

变化对象	第一轮	第二轮	变化原因	第二轮实际结果
结论措辞	方向性效果	候选方向	CI 跨零	避免过度外推
实验条件	固定 seed/90 天	保持不变	保证可比	版本可复现
数据与证据	合成日志	补充来源/限制字段	审计反馈	边界更清晰
人工判断	结果后审查	前置复核+停止条件	降低误判	保留失败轮次
停止与归档	CI/异常/证据不足	暂停升级	风险控制	保留失败轮次

第二轮结论

说明：第二轮完成的是工程与文档层面的反馈修订，尚未重新运行真人实验；因此第二轮结论只表示计划质量和审计边界改善。

说明：第二轮完成的是工程与文档层面的反馈修订，尚未重新运行真人实验；因此第二轮结论只表示计划质量和审计边界改善。

- 第二轮实际改善：输出边界更清楚，失败状态和人工判断被结构化保留，研究计划不再使用“已验证”措辞。
- 未改善/新代价：未完成真实数据校准、Qwen 实时日志和真人实验；增加了审计字段、人工复核时间和结果包存储成本。
- 结果只支持工程层面的迭代判断，不足以支持真实教育因果结论；需要真实数据或真人实验继续验证。
- 当前停止是提交基线的工程停止点：软件闭环已可复现，但真实验证、外部证据和更大样本仍需后续迭代。

P18 | 实际对照、消融与方案优势

团队实际完成的比较

实际对照方面	第一轮	第二轮	最终结论	证据状态	限制
科学逻辑	问题→仿真	问题→执行→反馈	闭环更完整	方向性	无真人验证
技术方法	固定 seed 运行	加审计/失败记录	可复核性提高	工程证据	无仪器
结果表现	g/CI 报告	加边界与人工节点	表达更谨慎	合成数据	CI 跨零

结果说明

- 科学逻辑：从一次性计划升级为目标—执行—反馈—修订闭环，明确虚拟结果与科学结论的边界。
- 技术方法：把配置、仿真、统计、异常处理和反馈写成可追踪版本；Qwen 只负责语言层，数值由确定性引擎产生。
- 结果表现：代表性案例可输出 5 个干预效应量、CI、轨迹和研究计划；最高点估计仍因 CI 跨零而保留为候选。
- 未改善部分及成本：真实数据接入、Qwen 实时证据、真人/物理实验和外部泛化仍未完成；需要数据授权、密钥管理和人工审计。

P19 | 总体结果、失败分析与适用边界

本作品实际总体表现

实际边界	已完成闭环	主要评价	重复/泛化	仍存在的风险
虚拟仿真	规划/执行/分析/反馈	可复现	固定 seed 案例	不能外推真人
真实数据	接口预留	未接入	无泛化结论	数据授权/校准
Qwen 实时	接口预留	离线回退已验证	未完成日志	密钥/成本

真实失败与边界

失败或边界	实际表现	原因	目前可处理程度
API 不可用	切换离线回退	无密钥/超时	可复现但非实时
数据缺失	停止并记录	字段或来源不完整	可识别，需人工
CI 跨零	保留候选	样本/波动/效果不确定	可报告，不可升级

- 范围：当前可在虚拟仿真环境中完成任务规划、执行、分析和反馈；尚未接入真实实验仪器。
- 资源：离线模式无需 API 费用；实时 Qwen、真实数据和真人实验会新增调用、数据授权、样本和伦理审查成本。
- 责任：研究者对目标、证据边界、人工判断和是否进入真人实验负责，系统不替代科研伦理或领域审查。
- 不支持的外推：不得把合成画像、虚拟效应量或单一案例外推为真实学生、真实因果或普遍科学规律。

P20 | 代码复现与提交材料

最终交付内容

提交项目	实际材料
源代码/运行说明	src/、README、固定 seed 案例与启动说明
Qwen 模型/调用凭证/日志	接口说明与脱敏字段；真实密钥不随材料提交
实验规划/执行/分析/反馈	本稿 P8-P18 及 case-20260821-100 运行包
实验 API/前端入口	src/api 与 frontend 入口可核验
真实实验/仪器证据	当前未接入，文档明确标注边界
可选演示视频	未作为正文完成条件，提供离线演示路径